

强化学习单阶倒立摆 – 课程门槛计划 v2(配对检验修正版)

版本说明：本文件是课程门槛计划的第 2 版，修正了第 1 版在统计设计上的缺陷。第 1 版采用的「60 回合 + 比基线高 10 个百分点」门槛已被否决，否决理由与具体数字见第二节，逐条清单见附录 D。执行本计划时请只依据本版。

文档用途：定义 P2 到 P6 的训练顺序、门槛、评估协议与失败处置。适用仓库 github.com/Cartpole-4/inverted-pendulum-rl (main 分支)。生成时进度：P1 已完成重训并通过验收，P2 尚未开始。

一、项目背景与当前状态

任务：单阶倒立摆 (cart-pole) 的 PP0 控制。动力学为纯 NumPy RK4 积分，策略与价值函数是一个约 13.5 万参数的 MLP (6 维观测输入，两个 256 宽隐层，有独立的 actor 与 critic 主干)。最终目标是「随机初始状态下稳定倒立」。

课程设计的基本论证：P1 到 P6 不改奖励、不改控制频率、不改作动器限幅，只单调放宽两件事，即初始角分布与回合终止阈值，并保持固定余量，即 $\theta_{fail} = \theta_{init} + 8.5$ 度。这样失败集随阶段单调收缩 (F1 包含 F2，依次包含到 F6)，已学会的行为在新阶段的得分只会变好或不变。

P1 当前状态：已完成重训。竖直起始 (± 2.86 度、静止、阈值 11.5 度) 成功率 100%、 θ RM S 0.15 度、回报 499.58。能力边界： ± 15 度成功率 95%、 ± 30 度 50%、 ± 45 度 45%。

本轮已修复四个缺陷，详见附录 B。其中最关键的一个是训练侧 `--terminate-angle` 缺少度到弧度的换算，导致 P1 到 P6 原本所有训练命令的角度阈值都大于 π 、从未生效。修复后 P1 重训， ± 15 度分布的成功率由 80% 提升到 95%，失败状态数由 6/20 降到 1/20。

二、第 1 版为何被否决(统计设计缺陷)

第 1 版协议为：每个分布跑 3 个 seed 各 20 回合 (共 60 回合)，门槛取「基线加 10 个百分点」，快速回归检查用 20 回合。精确二项功效分析显示，该协议测不出它声称要测的东西。

缺陷一：20 回合在 90% 基线下，于 80% 功效下检不出任何幅度的真实提升。它能发现的只有「彻底崩坏」量级，因此只能作为冒烟检查，不能作为门槛。

缺陷二：60 回合在 90% 基线下只能检出大于等于 9 个百分点的提升。若真实收益为 5 个百分点，会经常被误判为未达标。

缺陷三：P2 的门槛被设为 98%，因为在 95% 的基线上加 10 个百分点触到了上限。该门槛的功效不足属于设计错误而非样本量问题：即使策略真的达到 98%，通过率也只有约 63% 到 66%；而在 60 回合下，没进步却过关的假通过率高达 19%。把门槛恰好设在期望真值上，功效必然是抛硬币，加大样本量也无法纠正 (500 回合仍为 58%)。

根本原因：第 1 版把评估当作独立抽样。实际上评估是确定性的。环境按 seed 加 episode 编号重置，策略评估使用确定性动作，因此同一 seed 重跑会得到完全相同的初始状态集合，没有可以平均掉的运行噪声。正确的框架是配对比较。

三、统计设计(本版的核心修正)

性质一，确定性：策略与环境的组合在给定 seed 下完全可复现。因此同一批初始状态可以在两个 checkpoint 上分别评估，构成配对样本。

性质二，配对检验的功效远高于独立比较。精确 McNemar 检验结果显示：在旧策略失败、新策略成功的状态上，只要单向不一致对达到 6 个且没有反向破坏， $p = 0.031$ ；修好 8 个、弄坏 1 个， $p = 0.039$ ；修好 10 个、弄坏 2 个， $p = 0.039$ 。这正是课程要回答的问题，即这一阶段到底修好了什么。

性质三，独立抽样口径下样本量与可检出差异的关系(精确二项计算，单侧 α 为 0.05，功效 80%)。60 回合：基线 0.50 时可检出加 16 个百分点，基线 0.80 时加 13 个，基线 0.90 时加 9 个。200 回合：分别为加 10 个、加 7 个、加 6 个。500 回合：加 6 个、加 5 个、加 4 个。

性质四，95% 置信区间半宽。60 回合在 p 等于 0.90 时为加减 7.6 个百分点；200 回合为加减 4.2 个百分点；500 回合在 p 等于 0.50 时为加减 6.9 个百分点。

由此确定的取样规模：账本与门槛评估一律使用 200 回合(10 个 seed 各 20 回合)，成本约 1.4 分钟每分布。并明确承认：在 200 回合下，低于 3 到 4 个百分点的差异不可分辨，此类结果一律报告为「无可测变化」，不装作能分辨。

留出集：由于评估具有确定性且需要反复迭代，若始终对着同一批 seed 调参，会有对着测试集调参的风险。因此把 seed 分成两部分，开发集为 100 到 109，用于迭代与快速检查；留出集为 900 到 909，仅用于阶段验收判定。

四、账本与前置工具

账本按「分布乘初始状态」逐条记录，而不是只存汇总。每条记录的字段：分布标识、seed、回合序号、初始状态向量(x 、 θ 、 $\dot{x}$ 、 $\dot{\theta}$)、是否达到救回判据、结束原因(撞轨、倒杆、发散、时间上限)、步数、回合回报、 θ RMS。

账本初值取当前 P1(outputs/checkpoints/p1_rule/best.ckpt) 在六个分布上的 200 回合结果。六个分布为：D1 为 ± 2.86 度 upright 且静止；D2 为 ± 15 度；D3 为 ± 45 度；D4 为 ± 90 度；D5 为 ± 135 度；D6 为 ± 180 度且无角度终止。

前置工具需要新增，但工作量很小。其一，scripts/evaluate.py 的 --json-out 目前只导出汇总，需补充逐回合记录；其二，一个对比脚本，读入两份逐回合文件，输出精确 McNemar 结果、逐分布增量表与失败构成变化。

五、门槛与判定规则(修正版)

每个阶段 k 的判定由三项组成，全部满足才算通过。

第一项，配对不退步（主要判据，统计性）：在留出集的同一批状态上比较新旧 checkpoint。要求精确 McNemar 检验在 α 等于 0.05 下不显著变差，并且在任一已通过分布上，失败状态数相对账本不增加超过 2 个（200 回合制下 1%）。

第二项，绝对目标（次要判据，工程性）：在 D_k 上达到设定的成功率目标。目标按「下一阶段需要什么」设定，而不是按「基线加多少」设定，以避免第 1 版那种把门槛设在期望真值上的错误。

第三项，配对改善（仅在基线已接近或超过目标时启用）：若基线本身已达到该阶段的绝对目标，例如 P2 的情形（基线 95%，目标 98% 但工程上已可用），则要求配对检验显示显著改善，即单向不一致对至少 6 个；若不显著，该阶段记为「无可测收益」，不记为失败。

六、阶段与门槛总表（见文末表格）

七、评估协议（每阶段固定三步）

第一步，本阶段判定：在 D_k 的留出集上跑 200 回合，评估新 checkpoint，并与账本中同一批状态做配对比较。

第二步，防退化：在全部已通过分布上各跑 200 回合（留出集），使用同一套配对规则检查。

第三步，前瞻探针：在 $D_{(k+1)}$ 上跑一次 200 回合。这是信息性指标，不是门槛，用于判断该阶段对外推能力有没有贡献。

判读口径统一为：救回率（回合内曾达到 $|\theta| < 0.12 \text{ rad}$ 并连续保持 100 步）、失败状态数及其构成（撞轨与倒杆）、 θ RMS、平均保持时长。评估一律不传 `--max-seconds`，让视界自动跟随 checkpoint 记录的 500 步。

失败构成只有在归类缺陷修复之后才可见，而它才是可行动信息。当前 P1 在 ± 45 度的失败构成为倒杆 9 次、撞轨 2 次，主要矛盾是倒杆而不是撞轨。

八、失败处理策略

绝对目标未达但配对显著改善：属于方向对、幅度不够，把迭代数乘 1.5 重跑一次，例如 P2 从 450 提到 675。

配对未显著改善且绝对目标未达：把加宽步长减半，插入中间档，例如把 ± 45 度拆成 ± 30 度。

防退化违规：回退到上一阶段的 best. ckpt，用更小的步长重跑本阶段。

配对无可测变化但绝对目标已达标：记为「该阶段冗余」，直接推进下一阶段。阶段成本只有 10 到 20 分钟，不值得为它做优化。

训练出现 NaN 或发散：立即停止，检查 `log_std` 与学习率，不推进。

九、时间预算

训练单价实测为 1.313 秒每迭代(rollout 0.653 秒加 update 0.662 秒, 取自 p1_rule 的 metrics.jsonl)。P2 的 450 迭代约 9.8 分钟, P3 的 500 迭代约 10.9 分钟, P4 的 600 迭代约 13.1 分钟, P5 的 800 迭代约 17.5 分钟, P6 的 800 到 1000 迭代约 18 到 22 分钟。

评估成本: 每分布 200 回合约 1.4 分钟(实测单线程 0.82 毫秒每步, 500 步视界)。Phase 0 账本六个分布约 8 到 10 分钟。每阶段三项评估约 5 到 8 分钟。

合计: 含账本与前置工具, P2 到 P6 全部完成约 2 小时。由于单阶段重跑一次的代价只有 10 到 20 分钟, 门槛严格、该回退就回退是划算的策略。

十、每阶段交付

固定格式表格: 本阶段三项判定的结果(含精确 p 值与失败状态数); 全账本的逐分布增量(对比初值与最新值); 失败构成变化; 前瞻探针前后对比; 账本更新记录。所有数字均可复现。

十一、附录 A: 当前实测证据(20 回合, seed 123, 500 步视界)

竖直起始(± 2.86 度 upright 且静止, 阈值 11.5 度): 新 p1_rule 成功率 100%、失败 0/20、theta RMS 0.15 度、回报 499.58; 旧 cont_p1 成功率 100%、失败 0/20、RMS 0.31 度、回报 496.62。

± 15 度, 阈值 20 度: 新 成功率 95%、失败 1/20(撞轨 1 次)、RMS 1.66 度; 旧 成功率 80%、失败 6/20(全部为撞轨)、RMS 2.38 度。

± 30 度, 阈值 60 度: 新 成功率 50%、失败 10/20(撞轨 7 加倒杆 3); 旧 成功率 55%、失败 9/20(撞轨 8 加倒杆 1)。

± 45 度, 阈值 60 度: 新 成功率 45%、失败 11/20(撞轨 2 加倒杆 9); 旧 成功率 50%、失败 12/20(撞轨 7 加倒杆 5)。

旧权重的 ± 15 度、 ± 30 度、 ± 45 度三档成功率与 RMS 与 HANDOFF.pdf 表格逐位一致(80、55、50 与 2.38、7.51、19.56), 因此上述对比的基准可信。

十二、附录 B: 本轮已修复的缺陷

缺陷 1: scripts/train.py 的 --terminate-angle 缺少度到弧度的换算。CLI 按「度」设计(与 --init-angle-limit 及 evaluate.py 一致), 但训练时原样当弧度使用, 于是 handoff 中所有训练命令的阈值(11.5、23.5、53.5、98.5、143.5) 都大于 π , 实际从未生效。证据: 旧 cont_p1 的 checkpoint 里 env_config.terminate_angle 记录为 11.5 弧度, 等于 658.9 度。已修复, 并把默认值从 0.6 同步改为 34.4 度, 以保持默认行为不变。

缺陷 2: scripts/evaluate.py 在用户手动关闭实时窗口之后会退化成无窗口的批量评估; 配合 --max-seconds 0(视界为 None) 会形成无上限的死循环。实测该进程 5 秒墙钟消耗 76.8 秒 CPU(约 15 核)。已修复: mode_at_exit 改为在 try 之前初始化。

缺陷 3: scripts/evaluate.py 把导轨出界误报为 time cap, 进而计为「未倒」。已修复: 新增共享函数 ending_reason, 按物理标志(fell_over、out_of_rail、diverged) 优先判定; 渲染路径与批量路径共用同一函数, 避免两份逻辑再次漂移。

缺陷 4, 显示问题: 汇总行把平均步数印在 longest 之后。已修复为同时显示最长步数与平均步数。

另有一项环境层面的发现(未改训练代码): 默认 BLAS 与 OpenMP 线程池在评估时会造成大量自旋。实测 400 步: 默认线程池 CPU 9.47 秒、墙钟 0.62 秒(占用 15.3 核); 限制为单线程后 CPU 0.33 秒、墙钟 0.35 秒(占用 0.93 核)。已在 scripts/evaluate.py 导入 numpy 与 torch 之前设置 OMP_NUM_THREADS、MKL_NUM_THREADS、OPENBLAS_NUM_THREADS 为 1。scripts/train.py 未改动, 训练侧是否同样受益待测。

十三、附录 C: 关键复现命令

评估(本阶段门槛, 200 回合): conda run -n pendrl python scripts/evaluate.py --checkpoint outputs/checkpoints/<run>/best.ckpt --init-mode random --init-angle-limit 15 --terminate-angle 23.5 --episodes 20 --seed <seed> --no-render --no-video --no-plot, 对开发集 seed 100 到 109 与留出集 seed 900 到 909 分别执行。

评估(竖直起始): 把 --init-mode 换成 upright、--terminate-angle 换成 11.5, 并去掉 --init-angle-limit。

P2 训练: conda run -n pendrl python scripts/train.py --model cart --init-mode random --init-angle-limit 15 --init-rate-limit 0.5 --terminate-angle 23.5 --run-name p2 --max-epochs 450 --num-envs 16 --rollout-steps 256 --check-val -every-n-epoch 5 --log-std-init -1.5 --entropy-coef 0.003 --init-from outputs/checkpoints/p1_rule/best.ckpt --seed 0 --no-render

P3 到 P6 依次把 --init-angle-limit、--terminate-angle、--max-epochs、--init-from 换成: P3 为 45、53.5、500、p2; P4 为 90、98.5、600、p3; P5 为 135、143.5、800、p4; P6 为 180、0、800 到 1000、p5。

十四、附录 D: 第 1 版被否决的条款清单

否决条款 1: 账本规模为 3 个 seed 各 20 回合, 共 60 回合。理由: 90% 基线下 20 回合在 80% 功效下检不出任何提升。

否决条款 2: 门槛等于基线加 10 个百分点。理由: 60 回合只能检出大于等于 9 个百分点的提升; 且该规则在 95% 基线上产生 98% 的门槛, 功效仅约 63% 到 66%。

否决条款 3: 用 20 回合作为防退化门槛。理由: 该规模只能作为冒烟检查。

否决条款 4: 账本仅记录汇总指标。理由: 无法进行配对检验, 而配对检验是本计划统计功效的主要来源。

否决条款 5: 全部评估使用固定的 seed 123 到 125。理由: 缺少留出集, 存在对着测试集调参的风险。

阶段	初始分布 D_k	终止阈值	warm-start	迭代	绝对目标(200 回合)	主要判据
P1(已完成)	± 2.86 度 upright, 静止	11.5 度	无	200	已达标 100%	无
P2	± 15 度	23.5 度	p1_rule	450	>= 98%(196/200)	配对显著改善(基线 95% 已近目标)
P3	± 45 度	53.5 度	p2	500	>= 80%(160/200)	绝对目标 + 配对不退步
P4	± 90 度	98.5 度	p3	600	待 Phase 0 锁定(参考 60%)	绝对目标 + 配对不退步
P5	± 135 度	143.5 度	p4	800	待 Phase 0 锁定(参考 40%)	绝对目标 + 配对不退步
P6	± 180 度	0(无角度条件)	p5	800-1000	待锁定(参考 25%)	绝对目标(仅统计撞轨)